Міністерство освіти і науки України
Харківський національний університет радіоелектроніки
Кафедра програмної інженерії

ЗВІТ
з лабораторної роботи № 1
з дисципліни
«Технології розробки гібридних систем штучного інтелекту»
РОЗРОБЛЕННЯ RAG-СИСТЕМИ
ПРОЄКТУВАННЯ ПРОГРАМНОГО ЗАБЕЗПЕЧЕННЯ
Географічний довідник за Simple English Wikipedia

Виконав: студент групи ІПЗздм-26-1
Дідковський Олексій
Перевірив: Дашенков Д. С.

Харків 2026

1 МЕТА ТА ПОСТАНОВКА ЗАВДАННЯ

Мета роботи — набути практичних навичок попереднього проєктування програмного забезпечення RAG-системи як складеної системи штучного інтелекту. Проєкт має визначати користувача, джерело знань, компоненти, контракти між ними та порядок виконання запиту [1].

Об’єкт проєктування — локальний географічний довідник для студентів, які працюють з англомовними навчальними текстами. Назва репозиторію — rag-project-didkovskyi. Результатом першої лабораторної є проєктний документ і підготовлений робочий простір із версією lab-1.

Поставлено п’ять завдань: сформулювати сценарій використання та критерії якості; обрати відкритий корпус обсягом 500–10 000 документів; обґрунтувати чотири ключові технологічні рішення; побудувати архітектурну діаграму; створити базову структуру Git-репозиторію, README та тег lab-1 [1, с. 13–14].

1.1 Стислі теоретичні відомості

Складена ШІ-система розв’язує завдання завдяки взаємодії моделей, пошукових компонентів та звичайного програмного коду. Якість такого рішення залежить як від моделей, так і від організації обміну даними між компонентами [2].

RAG поєднує пошук у зовнішньому корпусі та генерацію відповіді на основі отриманого контексту. Документи розбивають на уривки, кодують у вектори й індексують. Під час оброблення запиту ретривер знаходить відповідні уривки, а генеративна модель формує відповідь із посиланнями на них [1, с. 12].

Контракт визначає структуру даних і допустимі результати на межі компонентів. Перевірка цитат дає змогу виявити посилання на відсутні уривки, проте сама наявність правильного ідентифікатора не гарантує фактичної правильності відповіді. Тому проєкт передбачає окреме оцінювання змісту.

2 СЦЕНАРІЙ ВИКОРИСТАННЯ

Цільовий користувач — студент, який опрацьовує англомовні тексти з географії та потребує стислої довідки з перевірюваним джерелом. Система допомагає уточнювати столиці, розташування країн, назви річок і значення базових термінів. Запит і відповідь подаються англійською мовою, відповідно до мови корпусу й моделі ембедингів.

Типовий запит: «What is the capital of France and which river flows through it?». Користувач вводить його в CLI. Система знаходить уривки про Францію та Париж і, за наявності потрібних відомостей, формує відповідь про столицю та Сену. Кожен використаний факт супроводжується ідентифікатором відповідного чанка; нижче подаються назви статей і URL. Це проєктний приклад, а не результат виконання готової системи.

Передумовою є наявність відповідних статей у робочому корпусі та доступність локального індексу і моделі. Основний потік складається з приймання запиту, пошуку, відбору до п’яти уривків, генерації, перевірки цитат і виведення відповіді. Якщо джерел недостатньо, система повідомляє про це та не доповнює відповідь непідтвердженими відомостями.

Гарна відповідь відповідає всім таким умовам: прямо розкриває запит; містить не більше 150 англійських слів без переліку джерел; усі перевірювані твердження підтверджуються наданими уривками; кожна цитата належить знайденому контексту; для відповіді зі статусом answered наведено принаймні одну цитату та URL. Для запитання з двома частинами необхідно висвітлити обидві або явно вказати, якої інформації бракує.

Поганою вважається відповідь із вигаданим фактом, неіснуючою цитатою, непідтвердженим твердженням, пропущеною частиною запиту або необґрунтованою впевненістю. Відповідь із правильним фактом, але без джерела також не відповідає призначенню довідника. Запит про актуальну погоду, поточні події чи тему поза корпусом має завершуватися контрольованою відмовою.

Цільові критерії приймання: Recall@5 $\geq$ 0,80; валідність ідентифікаторів цитат — 1,00; частка коректних відмов — щонайменше 0,80. Це заплановані критерії, а не результати вимірювань.

3 ВИБІР КОРПУСУ ДАНИХ

Обрано Simple English Wikipedia: набір wikimedia/wikipedia на Hugging Face, конфігурація 20231101.simple, розділ train [3]. Знімок текстів датований 1 листопада 2023 року. Один документ — одна стаття з полями id, title, url і text.

Предметне обмеження — географія. Планується сформувати 1 000 документів про країни, міста, річки, моря, гори та базові географічні поняття. Цей обсяг лежить у межах 500–10 000 документів, установлених методичними вказівками. Кількість чанків визначатиметься після очищення та поділу текстів і не підміняє кількість документів.

Проєктний спосіб відбору: отримати через MediaWiki API перелік сторінок категорії Category:Geography та її підкатегорій до глибини чотири; зберегти цей перелік із датою отримання; зіставити page_id зі статтями обраного знімка; вилучити дублікати й непридатні тексти; відібрати до 1 000 статей у порядку числового id. Обхід має враховувати продовження API-відповідей і цикли категорій [7].

Категорії API відображають стан на час відбору, а тексти — знімок 2023 року. Цю різницю потрібно явно зафіксувати у маніфесті. Вибраний список id, revision набору та контрольну суму маніфесту буде збережено під час отримання даних. Якщо придатних статей буде 500–999, фактичний обсяг документується; якщо менше 500, тематичний відбір переглядається до приймання корпусу.

Картка набору зазначає CC BY-SA 3.0 та GNU Free Documentation License [3]. Для текстів зберігатимуться назва статті, URL та історія авторів, позначення ліцензії й відомості про зміни. Умови конкретних текстів перевірятимуться під час завантаження; зображення не включаються.

Переваги джерела — доступна англійська мова і стабільні ідентифікатори. Обмеження: неповнота вибірки, різна якість, застарілі факти та нерівномірне представлення регіонів. Довідник призначений для навчального ознайомлення. На цьому етапі корпус обрано; завантаження і фактичні статистики не виконувалися.

4 ВИБІР ТЕХНОЛОГІЧНОГО СТЕКУ

Мова програмування — Python 3.11 або 3.12. Єдина мова для оброблення даних, викликів моделей, пошуку й CLI спрощує інтеграцію; бібліотеки обраного стеку мають Python-інтерфейси. Для початкової команди перегляду конфігурації достатньо стандартної бібліотеки.

Векторне сховище — Chroma в локальному режимі PersistentClient [5]. Воно дає змогу зберігати вектори, тексти та метадані на диску без окремого сервера або Docker. Для навчального корпусу це зменшує кількість компонентів, які потрібно адмініструвати.

Модель ембедингів — sentence-transformers/all-MiniLM-L6-v2 [4]. Модель підтримує англомовні тексти, формує 384-вимірні вектори та може працювати на CPU, що відповідає мові сценарію. Запити й чанки необхідно кодувати тією самою версією моделі; донавчання не передбачено.

Модель генерації — Llama 3.2 3B через Ollama, ідентифікатор llama3.2:3b [6]. Компактний локальний варіант усуває залежність від платного API та від квот зовнішнього сервісу під час роботи з готовим корпусом. Модель використовується за умовами Llama 3.2 Community License; це модель із доступними вагами та окремими ліцензійними умовами.

4.1 Ресурси та початкові параметри

У робочому середовищі визначено приблизно 16 ГБ оперативної пам’яті та відеоадаптер GeForce 930MX. Проєкт розрахований на CPU; придатність і швидкодію локальної генерації потрібно перевірити експериментально. Початкове завантаження даних, бібліотек і ваг потребує доступу до інтернету.

Початковий розмір чанка — 220 токенів токенізатора MiniLM, перекриття — 33 токени, тобто 15 %. Вибір обмежує довжину контексту ембедингу й відповідає діапазону 200–500 токенів із методички. Обрано косинусну відстань, до десяти кандидатів кожного пошукового методу, до п’яти чанків для генерації та RRF із $k = 60$. Параметри є початковими й не вважаються оптимізованими.

5 АРХІТЕКТУРА СИСТЕМИ

Систему розділено на підготовку знань і оброблення запиту. Спрощена блок-схема на рисунку 1 містить п’ять обов’язкових компонентів: Ingestion, векторний індекс, ретривер, генеративну модель та CLI. Деталізація у форматі Mermaid зберігається в reports/lab-1/architecture.md.

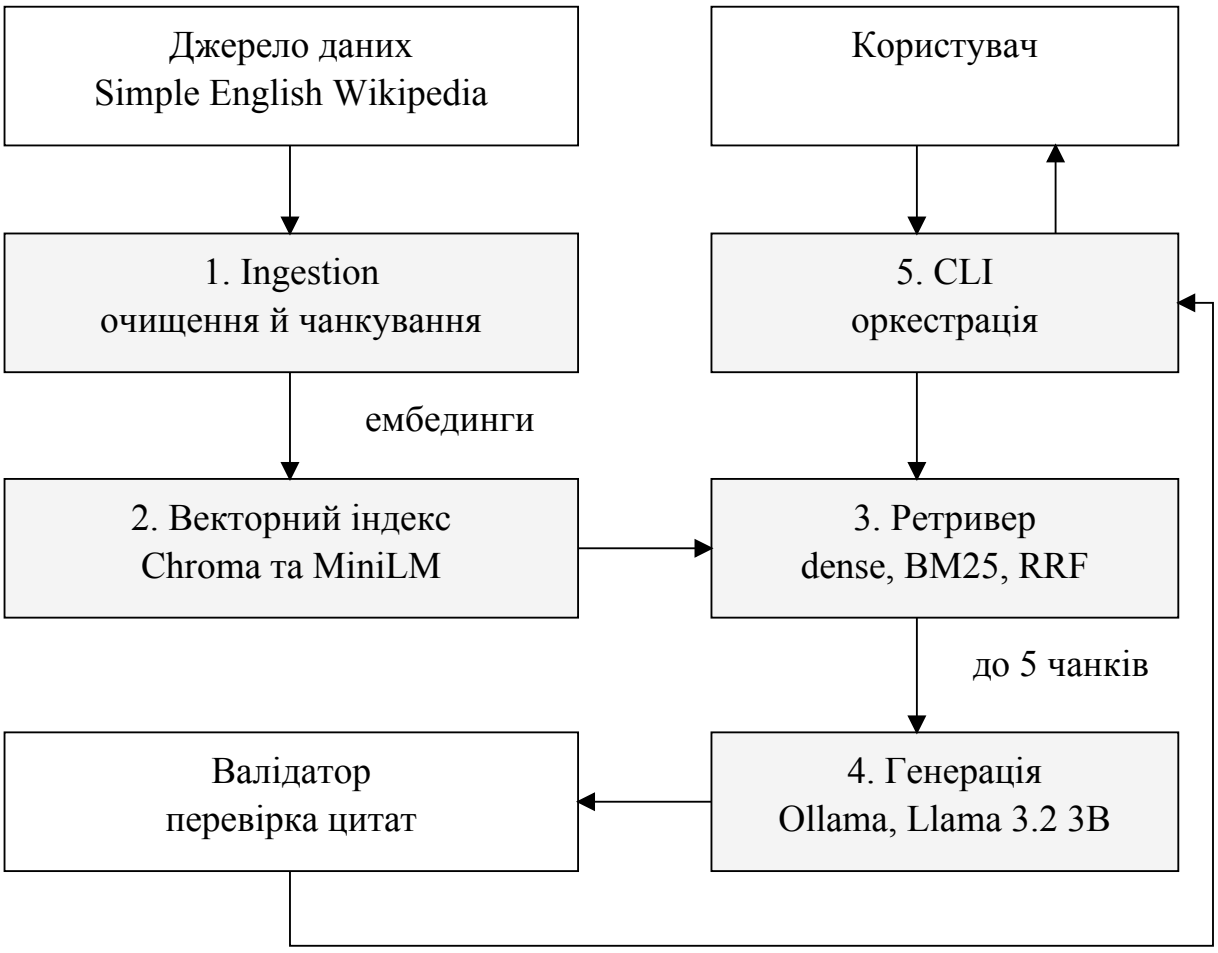


Рисунок 1 — Спрощена архітектура географічного RAG-довідника

Ingestion відповідає за відбір, очищення та чанкування. Під час індексації тексти кодуються MiniLM. Ретривер поєднує векторний пошук і BM25 через RRF. CLI оркеструє пошук, генерацію та перевірку цитат. Схема є результатом проєктування, а не свідченням реалізації всіх компонентів.

5.1 Контракти та оркестрація

Контракт прийому даних задає поля doc_id, title, url, source_snapshot, license, chunk_index, chunk_id і text. Ідентифікатор чанка має бути стабільним та унікальним, текст — непорожнім у UTF-8. Прив'язка до джерела зберігається після очищення й чанкування.

Контракт індексації вимагає вектора з 384 скінченних чисел і відповідності кожного вектора конкретному chunk_id. Метадані колекції мають визначати модель, її ревізію та параметри чанкування. Зміна цих параметрів потребує перебудови індексу.

Контракт ретривера — список не більше п'яти різних чанків із текстом, chunk_id, URL та оцінкою ранжування. Порожній список спричиняє повідомлення про недостатність даних без виклику генеративної моделі. Оцінка подібності сама по собі не є ймовірністю правильності майбутньої відповіді.

Контракт генерації визначає статус answered або insufficient_context, текст answer і список citations. Для answered потрібна принаймні одна цитата. Усі ідентифікатори повинні належати контексту поточного запиту; зв'язок тексту твердження зі змістом джерела перевірятиметься окремо.

У разі порушення контракту цитування допускається одна повторна генерація з уточненою інструкцією. Повторна помилка завершується контрольованою відмовою. Недоступність індексу чи тайм-аут Ollama повертається як помилка виконання, щоб не змішувати технічну несправність із недостатністю джерел.

Послідовність оброблення запиту: CLI приймає текст; ретривер кодує запит, виконує dense та BM25, об'єднує результати; генератор отримує запит і контекст; валідатор перевіряє цитати; CLI виводить відповідь із джерелами або повідомлення про відмову. Підготовка корпусу та індексація виконуються окремими процесами до оброблення запитів.

Основні проєктні ризики: нерелевантні результати пошуку, непідтверджені факти у відповіді та перевищення доступних ресурсів. Відповідні заходи — оцінювання пошуку, перевірка цитат разом із ручною перевіркою фактів та обмеження кількості контекстних чанків. На цьому етапі ефективність заходів ще не вимірювалася.

6 РОБОЧИЙ ПРОСТІР І РЕЗУЛЬТАТИ

Використано Git-репозиторій rag-project-didkovskyi у гілці main. У корені підготовлено README.md з описом сценарію, стеком і послідовністю встановлення Python-середовища, бібліотек та Ollama. Створено обов'язкові каталоги src/, config/ і reports/.

У src/ виділено підкаталоги ingestion/, embeddings/, retrieval/, generation/ та evaluation/ з описом майбутньої відповідальності. Ці каталоги задають структуру проєкту. Додаткова команда перегляду TOML-конфігурації працює на стандартній бібліотеці Python:

```
python -m src --show-config
```

Команда виводить структурований JSON із вибраними параметрами. Це перевірка робочого простору; вона не виконує пошук чи генерацію. Проєктні параметри зберігаються у config/project.toml. Звіт, його текстовий оригінал і Mermaid-схема розміщені у reports/lab-1/.

Вимоги зіставлено з оригіналом методичних вказівок, зокрема зі сторінками 6–10 та 12–14. Карта відповідності збережена у docs/methodology.md разом із контрольною сумою PDF. Під час підготовки перевірено структуру TOML, виведення конфігурації, наявність обов'язкових компонентів схеми та форматування PDF. Детальний журнал розміщено у reports/lab-1/submission.md.

Результатами першої лабораторної є конкретний сценарій з критеріями якості, обраний відкритий корпус з оцінкою обсягу, чотири обґрунтовані технологічні рішення, блок-схема, контракти та базова структура репозиторію. Експериментальні метрики й приклади відповідей готової RAG-системи на цьому етапі відсутні.

Репозиторій: https://github.com/AlexDidkovskiy/rag-project-didkovskyi

Версія першої лабораторної: https://github.com/AlexDidkovskiy/rag-project-didkovskyi/tree/lab-1

Для подання необхідно завантажити report.pdf на DL і пройти захист. Посилання на відеозапис додається лише за асинхронної форми захисту; відеозапис у межах підготовки матеріалів не створювався.

ВИСНОВКИ

Спроєктовано географічний RAG-довідник для студентів. Визначено сценарій і критерії підтвердженості відповідей, цитування та відмов. Обрано тематичний корпус Simple English Wikipedia орієнтовним обсягом 1 000 документів, джерело й ліцензії.

Обґрунтовано використання Python, Chroma, all-MiniLM-L6-v2 та Llama 3.2 3B через Ollama. Побудовано архітектурну схему з п’ятьма обов’язковими компонентами, описано контракти та оркестрацію. Підготовлено структуру репозиторію, конфігурацію та README. Отримані результати відповідають етапу попереднього проєктування; працездатність повної системи ще потребує реалізації та вимірювань.

ДЕКЛАРАЦІЯ ЩОДО ВИКОРИСТАННЯ ШІ

Для підготовки матеріалів застосовано OpenAI Codex, модель поточного етапу gpt-6.1-sol. Точну внутрішню ревізію розгортання інструмент не повідомляє. ШІ працював як помічник із аналізу методичних вимог, формулювання сценарію, вибору стеку, підготовки тексту, схеми, конфігурації та допоміжного коду.

Обсяг використання: за допомогою ШІ створено первинні редакції всіх змістових розділів цього звіту, README, карти вимог, Mermaid-схеми, конфігурації та скриптів перегляду конфігурації і складання PDF. Персональні відомості надав автор. Результати роботи готової RAG-системи не генерувалися та не подавалися як виконані експерименти.

Під час підготовки помічник звірив вимоги з локальним PDF та технологічні відомості з офіційними картками й документацією. Виправлено початкове припущення щодо потреби готової RAG-системи вже в першій роботі; уточнено каталог reports/lab-1/, обов’язкове посилання на тег і відмінність документів від чанків. Команду читання конфігурації запущено, PDF перевірено за структурою та візуально.

Особисте прочитання, перевірка змісту та пояснення рішень на захисті є відповідальністю автора. Верифікація автором не підміняється перевіркою помічника. ШІ прискорює підготовку, проте потребує звірення з першоджерелами та розмежування запланованих і виконаних дій.

ПЕРЕЛІК ДЖЕРЕЛ ПОСИЛАННЯ

1. Методичні вказівки до виконання лабораторних робіт з дисципліни «Технології розробки гібридних систем штучного інтелекту» / упоряд. Д. С. Дашенков. Харків : ХНУРЕ, 2026. 32 с. Електронне видання.

2. Zaharia M., Khattab O., Chen L. et al. The Shift from Models to Compound AI Systems. Berkeley Artificial Intelligence Research Blog. 2024. URL: https://bair.berkeley.edu/blog/2024/02/18/compound-ai-systems/ (дата звернення: 29.10.2026).

3. Wikimedia. Wikipedia dataset. Конфігурація 20231101.simple. Hugging Face. URL: https://huggingface.co/datasets/wikimedia/wikipedia (дата звернення: 29.10.2026).

4. Sentence Transformers. all-MiniLM-L6-v2. Картка моделі. URL: https://huggingface.co/sentence-transformers/all-MiniLM-L6-v2 (дата звернення: 29.10.2026).

5. Chroma. Getting Started. Офіційна документація. URL: https://docs.trychroma.com/docs/overview/getting-started (дата звернення: 29.10.2026).

6. Ollama. Llama 3.2 3B. Картка моделі. URL: https://ollama.com/library/llama3.2:3b (дата звернення: 29.10.2026).

7. MediaWiki. API Categorymembers. Офіційна документація. URL: https://www.mediawiki.org/wiki/API:Categorymembers (дата звернення: 29.10.2026).